UNIVERSIDAD SAN SEBASTIÁN

Facultad de Ingeniería y Tecnología

Asignatura: Ciencia de Datos y Big Data

Profesor: Israel Naranjo Retamal

Evaluación: Solemne II – Análisis de Datos Masivos, Evolución Histórica del Maratón y Procesamiento de Lenguaje Natural (NLP)

Puntaje Total: 100 puntos (Exigencia: 60%)

Descripción General y Contexto del Proyecto

Los Juegos Olímpicos modernos representan uno de los eventos longitudinales con mayor riqueza de datos estructurados y desestructurados del mundo, abarcando más de un siglo de historia (desde Atenas 1896 hasta la actualidad).

En esta evaluación, los estudiantes asumirán el rol de **Científicos de Datos Deportivos e Históricos**. El trabajo se divide en dos grandes etapas:

1. **Macroanálisis Global e Histórico del Maratón:** Exploración, limpieza y análisis de la prueba reina del atletismo (*Maratón Masculino*) a lo largo de todas las ediciones olímpicas, identificando los podios históricos (Top 3) y la evolución de los registros temporales.

2. **Microanálisis de Contexto y NLP (Caso Manuel Plaza):** Profundización en la gesta del atleta chileno Manuel Plaza en los Juegos Olímpicos de Ámsterdam 1928, cruzando los datos cuantitativos con técnicas de Procesamiento de Lenguaje Natural y fuentes documentales históricas.

Dataset: https://www.kaggle.com/datasets/piterfm/olympic-games-medals-19862018

SECCIÓN I: Macroanálisis y Evolución Histórica del Maratón Olímpico (40 Puntos)

Utilizando el dataset histórico de los Juegos Olímpicos de Kaggle (ej. *Olympic Summer & Winter Games*), cargue la información en un entorno de Python (pandas, numpy, matplotlib/seaborn) y desarrolle las siguientes tareas analíticas:

1. Ingesta, Limpieza y Filtrado de la Prueba (10 Puntos)

- **Carga de datos:** Cargue el dataset consolidado de atletas y resultados históricos.
- **Filtrado específico:** Aislar exclusivamente los registros correspondientes a la competencia de **Maratón Masculino** (*Marathon Men*) a lo largo de toda la historia olímpica registrada.
- **Limpieza de Tiempos:** Escriba un script en Python para unificar el formato de los tiempos de llegada (convertir marcas a segundos totales o formato timedelta de pandas) para permitir comparaciones cronológicas precisas, eliminando valores nulos o descalificados sin marca.

2. Extracción de los Tres Primeros Lugares Históricos (15 Puntos)

- Genere una tabla resumen o DataFrame en Python que contenga el **podio histórico (Top 3: Oro, Plata y Bronce)** de la maratón para cada una de las ediciones de los Juegos Olímpicos (desde Atenas 1896 hasta la edición más reciente disponible).
- La tabla final debe mostrar claramente las columnas: Año, Ciudad, Puesto (Medalla), Atleta, País/Equipo y Tiempo.

3. Visualización y Análisis de la Brecha Temporal (15 Puntos)

- Construya una visualización gráfica (por ejemplo, un gráfico de línea o dispersión con matplotlib o seaborn) que muestre la **evolución del tiempo del ganador de la medalla de oro** en la maratón a lo largo de los años.
- Analice e identifique en un párrafo breve: ¿Cómo ha evolucionado la marca ganadora a lo largo de un siglo? ¿Se aprecian saltos drásticos en ciertas décadas (por ejemplo, debido a cambios en pistas, nutrición o tecnología deportiva)?

SECCIÓN II: Profundización Histórica y Caso de Estudio – Manuel Plaza en Ámsterdam 1928 (50 Puntos)



Haciendo un zoom-in desde la macroestructura global hacia la historia humana, la evaluación se focaliza en el hito del deportista chileno **Manuel Plaza Reyes** y su histórica medalla de plata en los Juegos Olímpicos de **Ámsterdam 1928**.

4. Aislamiento y Contexto Cuantitativo del Podio de 1928 (10 Puntos)

- A través de código en Python, filtre específicamente los registros de la maratón de **Ámsterdam 1928** extraídos en la Sección I.
- Presente los datos exactos del podio de esa edición:
  - 🥇 Boughera El Ouafi (Francia) - 02:32:57
  - 🥈 **Manuel Plaza Reyes** (Chile) - 02:33:23
  - 🥉 Martti Marttelin (Finlandia) - 02:35:02
- Calcule analíticamente la diferencia exacta en segundos con la que Manuel Plaza quedó del oro olímpico.

5. Simulación de Integración con Fuentes Documentales (15 Puntos)

- *Diseño de pipeline de búsqueda:* Suponga que su script debe enriquecer este dato numérico conectándose a repositorios externos o motores de búsqueda de crónicas históricas.
- Escriba un bloque de código conceptual o función en Python que reciba los metadatos de Manuel Plaza (Atleta, Año, Ciudad) y simule la ingesta de un mini-corpus de texto con fragmentos de periódicos de 1928 que describan su origen socioeconómico (suplementero en Santiago) y su entrenamiento en el antiguo Parque Cousiño.

6. Procesamiento de Lenguaje Natural (NLP) sobre Crónicas Históricas (15 Puntos)

- Utilizando un corpus de texto histórico provisto o simulado sobre la participación de Manuel Plaza:

- Aplique un pipeline de NLP básico usando librerías como `spaCy` o `NLTK`: limpieza de texto, tokenización y eliminación de *stopwords*.
- Ejecute **Extracción de Entidades Nombradas (NER)** para identificar automáticamente las locaciones geográficas clave (ej. *Ámsterdam, Santiago, Parque Cousiño*), fechas y actores involucrados.
- Realice un análisis léxico o de polaridad/sentimiento para evaluar si las crónicas de la época describían el logro de Sudamérica con un tono épico, de sorpresa o de precariedad.

7. Síntesis Automatizada de Datos y Texto (Data-to-Text) (10 Puntos)

- Diseñe una función en Python llamada `generar_cronica_historica(df_stats, entidades_nlp)` que reciba:

  1. Los datos duros del dataset (Tiempo: 2h 33m 23s, Medalla de Plata, diferencia de 26 segundos).

  2. Las entidades y el contexto sociohistórico extraído por NLP.

- La función debe estructurar y retornar un **reporte narrativo integrado** que fusione la estadística fría del maratón olímpico con la narrativa humana del hito de 1928.

SECCIÓN III: Pregunta Conceptual y de Cierre (10 Puntos)

8. **Reflexión Crítica sobre Big Data e Historia (10 Puntos):** En un ensayo breve (máximo 15 líneas), responda analíticamente: *¿Qué valor agregado real aporta combinar un dataset tabular masivo de Kaggle (como los podios históricos del maratón) con técnicas de Procesamiento de Lenguaje Natural (NLP) y búsqueda documental, en comparación con realizar únicamente un análisis estadístico cuantitativo tradicional?* Fundamente utilizando el caso de Manuel Plaza y la magnitud temporal transcurrida (1928 - 2028).